분류-검색어사전에 기초한 단어결합형식의 주제어추출방법

최 영 희

위대한 령도자 김정일동지께서는 다음과 같이 교시하시였다.

《콤퓨터가 출현하고 그에 따라 정보기술이 발전하면서 사람들이 환상적으로만 생각하던 문제들이 현실로 되고있으며 자연을 정복하고 세계를 개조하는 인간의 창조적힘은 더욱더 위력한것으로 되고있습니다.》(《김정일선집》 중보판 제20권 352폐지)

단순한 계산수단으로 출현하였던 콤퓨터는 오늘 방대한 정보량을 계산하는 만능의 정 보처리기로 발전하였다.

콤퓨터의 발전은 도서관에서 품이 많이 들고 주제분석의 일치성에 대한 질적수준을 보 장하기 힘든 분류색인을 자동으로 할수 있는 전망을 열어놓았다.

일반적으로 주제어는 품사적으로 명사만을 허용한다. 그러므로 주제어의 어휘형식도 단순어와 합성어, 단어결합형식의 명사이다.

여기서는 단순어와 합성어, 단어결합을 다음과 같이 정의하고 리용한다.

단순어는 하나의 말뿌리로 된 단어를, 합성어는 두개이상의 말뿌리들이 공백없이 결합 되여 이루어진 단어를, 단어결합은 두개이상의 단어들이 공백을 사이에 두고 결합되여 이 루어진것을 말한다.

- ㅇ 단순어: 발굴, 경제, 분배, 교환, 예술, 서고, 문맥, 성구,…
- o 합성어: 언어구조, 독서지도, 조별련맹전.···
- 단어결합: 생산수단의 상품적형태, 정치도덕적 및 물질적자극의 결합, 근로자들의 추가적혜택…

정보학분야의 사전들에서 리용되는 주제어의 올림말들은 어휘적으로 보면 단순어와 합성어, 단어결합형식으로 이루어진다. 그러므로 자동색인에서 주제어추출은 형태단어모임으로부터 단순어와 합성어, 단어결합형식의 주제어들을 끌어내는 과정이라고 말할수 있다.

일반적으로 주제어에는 단어결합이나 특이한 경우의 합성어(례를 들어 《건간장》, 《된장》, 《너도밤나무》)를 제외하고는 토가 붙지 않는다. 그러므로 단어결합형식의 주제어추출은 이미 확정된 형태단어모임에서 둘이상의 형태단어들이 문법규칙에 따라 구조적으로 서로 맞물려 배렬되여있는 단어들에서 추출하여야 한다.

정보학실천에서 리용되는 사전들에서는 단어결합형식의 올림말이 차지하는 비중이 비교적 높다. 그것은 하나의 단어결합형식으로 이루어진 학술용어의 구성요소들을 분해하면 전문용어로서의 본래의 의미가 상실되거나 의미폭이 달라지는 경우가 생기기때문이다.

단어결합이 정보학실천에 큰 영향을 주지만 실천적으로 단어결합형식의 주제어추출은 품이 많이 든다.

단어결합형식의 주제어추출이 힘든 원인의 하나는 단어결합이 두개이상의 단어들이 문 법적으로 서로 련결되여 련속적인 고리를 이루고 결합되여있기때문이다. 일반적으로 형태단어모임에서 단어결합형식의 올림말을 이루는 첫 단어와 같은 단어가 있다고 하여 그와 련결되는 뒤단어는 같은것도 있고 같지 않은것도 있다.

실례로 o 조국과 나

- ㅇ 조국과 인민
- ㅇ 조국과 영생
- ㅇ 조국과 영생하는 영웅

례에서 보는바와 같이 시작단어는 같지만 그와 결합되는 단어는 서로 다르다. 그러므로 단어결합을 이루는 첫 단어가 같다고 하여도 그뒤에 련결되는 모든 단어들에 대한 비교를 하여야만 단어결합형식의 주제어를 추출할수 있다. 바로 이것이 단어결합형식의 주제어선정을 힘들게 하는 원인의 하나로 된다.

단어결합형식의 주제어추출이 힘든 원인의 다른 하나는 실천에서 의미는 같으나 집필자의 표기형식과 사전적단어표기에서 일련의 불일치가 있기때문이다. 이러한 불일치는 집필자가 내용서술에서 그것을 표현하는 사전적단어표기에 대한 무관심성과 굳어진 문체와도 관련된다.

의미상 같거나 류사하다고 보고 사전적단어결합을 기준으로 하여볼 때 집필자와 사전 적단어표기사이의 불일치경우를 두가지 부류로 갈라볼수 있다.

부류	단어결합형식의 올림말	집필자의 표기
1부류	o 당창건위업의 완성 o 축적소비균형의 법칙	o 당창건위업완성 o 축적소비균형법칙
2부류	사회발전에서 개인의 역할사회발전의 주체적요인축적소비균형의 법칙	 사회발전에서의 개인의 역할 사회발전에서의 주체적요인 축적과 소비균형의 법칙 축적과 소비에서 균형법칙

표 1. 집필자의 단어표기와 분류-검색어사전의 올림말표기사이의 불일치 부류

여기에서 보는바와 같이 1부류는 토가 삭제되여 단어결합으로부터 합성어로 변하는 경우이고 2부류는 같은 단어결합형식인데 일부 토들이 보충되는 경우이다.

두 경우에 사전적표기와 집필자의 표기에서 일부 글자 또는 글자렬이 삭제 또는 삽입 되기는 하지만 의미상견지에서는 변함이 없다. 이러한 현실은 단어결합형식의 주제어추출 을 힘들게 하는 또 다른 하나의 원인으로 된다.

바로 이러한 원인으로 하여 선행한 연구에서는 대상본문속에서 직접 단어결합형식의 주제어를 추출하는것이 아니라 후조합의 방법으로 단어결합형식의 주제어를 만들었다. 그러나 이 방법은 본문속에 내재하는 집필자의 의도를 정확히 반영하는데서 일련의 문제점들이 있는것으로 하여 주로 주제색인에서 많이 리용하였다.

일반적으로 단어는 이미 일반화되여있기때문에 문장론적구조밖에서는 고도의 추상성을 띠고있으나 그것이 일단 단어결합의 구성속에 들어갈 때에는 더욱 정밀화되고 구체화되며 따라서 그 일반화와 추상화의 성격은 그만큼 낮아지게 된다.

례를 들어 단어 《나무》는 자연계에 존재하는 어떠한 나무도 가리킬수 있을만큼 매

우 일반적이고 추상적인 명명으로 되지만 단어결합 《백두의 봇나무》는 바로 그 명명을 통하여 봇나무가 아닌 모든 나무들이 부정되면서 그만큼 구체화되고 정밀화된 나무를 가리킨다. 이것은 결합되는 단어의 수가 많아질수록 의미가 더욱더 구체화된다는것을 말해준다. 그러므로 분류—검색어사전에서는 해당 전문분야에서 굳어진 학술용어라든가 단어결합형식의 주제어를 리용하여야만 자기의 의미를 정확히 표현할수 있다고 보는 단어들은 그대로 올림말로 수록하고 리용한다. 그러한 리유로 하여 언어학사전과는 달리 정보학실천에서 리용되는 사전들에서는 단어결합형식의 올림말이 차지하는 비중이 비교적 높다.

정보학분야에서 리용되는 사전들을 분석하여보면 단어결합형식의 올림말들은 자연과 학분야에는 극히 적고 사회과학분야에 많다.

그러면 분류-검색어사전에 수록된 올림말들에 있는 단어결합의 류형들을 구체적으로 보기로 하자.

- ㅇ 명사*
 - 반일인민유격대 남만진출, 간또대지진때 조선인학살
- o (명사+반점)*+명사여격+동사규정형+명사 당성, 로동계급성, 인민성에 관한 로작
- o 명사+반점+명사* 성별, 나이별사망률
- o 명사+반점+명사속격+명사 당성, 로동계급성의 원칙
- o 명사+이음부사+명사+명사속격+명사 직맹 및 청년동맹 대표들의 답사
- 명사+이음부사+명사여격+동사규정형+명사식량 및 농업증산에 관한 평양선언
- o 명사*+이음부사+명사* 공중 대 지상로케트
- 명사*+이음부사+명사속격+명사*수개국 공산당 및 로동당들의 보도국회의
- 명사+이음부사+명사여격+동사규정형+명사 관세 및 무역에 관한 일반협정
- 명사+동사규정형+명사가격에 대한 수요신축성곁수
- o 명사속격+명사* 백두산서남부에로의 진출
- 명사속격+명사+(반점+명사)*
 인민경제의 주체화, 현대화, 과학화
- 명사속격+형용사규정형+명사 과거의 어린 탄부(미술)
- 명사속격+명사속격+명사수령의 후계자의 유일적령도체계

- 명사속격+명사조격+동사규정형+명사 혁명의 총대로 지켜갈 미래
- 명사속격+명사여격+동사규정형+명사 미의 기준에 관한 문제
- o 명사대격+동사규정형+명사 강의를 통하 교양
- 명사대격+명사조격+동사규정형+명사 백두산근거지를 중심으로 한 항일무장투쟁
- 명사대격+동사규정형+명사 구호문헌을 통하 교양
- 명사대격+명사조격+동사이음형*+동사규정형+명사사상을 기본으로 틀어쥐고나갈데 대한 원칙
- o 명사대격+부사+동사이음형+동사규정형+명사 세금제도를 완전히 없앨데 관한 법령
- 명사조격+동사규정형+명사 제갈림으로 이루어진 가족
- 명사구격+명사*경제건설과 국방건설병진로선 관현악과 합창
- 명사구격+명사여격+동사규정형+명사 발전과 경제협정에 관한 결의
- o 명사구격+명사속격+명사 공업과 농업의 생산적련계
- 명사여격+동사규정형+명사속격+명사 인간에 의한 세계의 지배
- 명사위격+명사속격+명사구격+명사 사회에서 인간의 지위와 역할
- 명사위격+명사주격+동사규정형+명사 사회적운동에서 인민대중이 노는 역할
- 명사여격+동사규정형+명사 인민대중에게 의거하는 방법
- 명사여격+동사규정형+명사+반점+명사 세계에 대한 견해, 관점, 립장
- 명사위격+명사문학예술에서 주체확립
- 명사여격+동사규정형+명사속격+명사 사람에 의한 세계의 개조
- o 명사규정형+명사 자주적인 사상의식

분류-검색어사전에 오른 단어결합형식의 올림말들의 류형을 종합하면 다음과 같다.

부사+형용사규정형+명사

우에서 서술하 단어결합종합모형에서 괄호 《{{}》는 그안에 서술된 항목중의 임의의 항 목과의 결합가능성을, 《[]》는 선택성을, 기호 《*》은 개수의 임의성을 의미한다.

보는바와 같이 단어결합형식의 올림말의 형태가 매우 다종다양하다.

일반적으로 단어결합은 문장론적해석을 통하여서만 그 의미를 파악할수 있다. 그러므 로 응용언어학에서는 문장에서 단어들의 라렬구조를 밝혀내기 위하여 문법규칙을 작성하 고 그에 기초하여 문장론적해석을 진행한다. 다시말하여 1차워으로 라렬된 단어들의 호상 결합을 문법규칙에 따라 하나하나 밝혀내고 총체적으로 문장의 구조를 밝힌다.

그러나 자동분류색인에서는 문장론적해석을 통하여 단어결합형식의 주제어를 추출할 수 없다. 그것은 본문속에 존재하는 무수한 단어결합이 모두 문헌의 분류에 영향을 주는 주 제어로서의 가치를 가진다고 볼수 없기때문이다.

집필자의 의도에 맞는 가장 정확한 단어결합형식의 주제어는 본문속에 있다. 대상본문 에 존재하는 단어결합들가운데서 실지로 문헌분류에 영향을 주는 단어는 분류-검색어사 전에 수록된 단어결합형식의 올림말과 일치하는 단어이다. 그러므로 자동분류색인을 위한 단 어결합형식의 주제어추출은 대상본문에서 단어결합형식의 올림말을 얻어내는 방법으로 하는것이 합리적이다.

대상본문에서 분류-검색어사전에 기초한 단어결합형식의 주제어를 추출하기 위한 언어공학적원리는 대상본문을 하나의 글자렬모임으로 보고 거기에서 단어결합형식의 올림말과 일치하는 부분글자렬을 얻어내는것이다.

론문에서는 주제어추출속도를 높이기 위하여 대상본문을 n개 글자씩 분할하여 색인화 일을 형성하고 그에 기초하여 주제어를 추출하는 방법을 서술하였다.

이 방법을 구체적으로 보기로 하자.

먼저 대상본문의 글자렬을 *n*개의 글자로 이루어진 실마리어로 분할하고 매 실마리어에 대한 ASCII 코드값이 첨부된 색인화일을 작성한다.

대상본문의 글자렬분할은 다음의 규칙에 기초하여 진행한다.

규칙1. n의 최소값은 4이상이여야 하며 최대값은 가장 긴 단어결합형식의 올림말의 글 자개수와 같아야 한다.

규칙 2. 글자가운데에 있는 공백을 비롯한 모든 기호들도 하나의 글자로 처리한다.

규칙 3. 시작글자가 공백이면 무시하지만 마지막글자가 공백인 경우에는 무시하지 않는다.

규칙 4. 글자렬의 분할은 나머지글자의 개수가 n과 같거나 작을 때까지 진행한다.

실례로 우의 규칙에 기초하여 본문 《한문장안에서 일정한 단어나 표현이 쓰이면 뒤에 있는 문장성분도 그에 알맞는 단어나 표현이 따라올것을 요구하는 현상을 가리켜 문장성분의 어울림이라고 한다.》를 9개 글자로 이루어진 실마리어로 분할하면 다음과 같은 실마리어화일이 얻어진다.

	표 전 3개 글시도 이무이한 글미디어
$N_{\!$	실마리어
1	한문장안에서 일정
2	문장안에서 일정한
3	장안에서 일정한
4	안에서 일정한 단
5	에서 일정한 단어
•••	
52	리켜 문장성분의
53	켜 문장성분의 어
54	문장성분의 어울림
55	장성분의 어울림이
56	성분의 어울림이라
57	분의 어울림이라고
58	의 어울림이라고
59	어울림이라고 한다

표 2. 9개 글자로 이루어진 실마리어

얻어진 실마리어에 대응하는 ASCII 코드를 얻고 그것을 정돈하여 색인화일을 만 든다.

표 3. 9개 글자로 이루어진 실마리어색인화일

	실마리어	ASCII 코드
51	가리켜 문장성분의	234176128235166172236188156322351721842361581652 36132177235182132236157152
42	것을 요구하는 현	234178131236157132322361541482341811722371491522 3513814832237152132
45	구하는 현상을 가	234181172237149152235138148322371521322361311292 3615713232234176128
•••		
18	면 뒤에 있는 문	235169180322351461642361511443223615813623513814 832235172184
2	문장안에서 일정한	235172184236158165236149136236151144236132156322 36157188236160149237149156
23	문장성분도 그에	235172184236158165236132177235182132235143132322 3418318423615114432
54	문장성분의 어울림	235172184236158165236132177235182132236157152322 36150180236154184235166188
26	분도 그에 알맞는	235182132235143132322341831842361511443223614914 0235167158235138148
57	분의 어울림이라고	235182132236157152322361501802361541842351661882 36157180235157188234179160
1	한문장안에서 일정	237149156235172184236158165236149136236151144236 13215632236157188236160149
9	한 단어나 표현이	237149156322351391682361501802351301523223714515 6237152132236157180
48	현상을 가리켜 문	237152132236131129236157132322341761282351661722 3618815632235172184
14	현이 쓰이면 뒤에	237152132236157180322361471762361571802351691803 2235146164236151144
37	현이 따라올것을	237152132236157180322351481762351571882361521722 3417813123615713232

다음은 분류-검색어사전에서 단어결합형식의 올림말들을 선택하고 그에 대응하는 ASCII 코드값이 첨부된 단어결합형식의 올림말색인화일을 작성한다.

실례로 단어결합형식의 올림말이 다음과 같이 주어졌다고 하자.

No	단어결합		단어결합
1	가격제정의 통일성	11	문장성분밖에 오는 어
2	가격에 대한 수요신축성곁수	12	문장성분의 바른 성분
3	가극무대미술의 립체화원칙	13	문장성분의 바뀐 차례
4	가극음악의 절가화원칙	14	문장성분의 조응
5	격범주의 변화	15	문장성분의 어울림
6	과학의 사회적기능	16	문장성분의 의미적련관
7	관광객의 봉사수요		문장의 문법적성분화
8	노래보급을 통한 교양		문체의 발전
9	부문별행정경제기관		붓글씨쓰는 방법
10	무용음악의 명곡화	20	붓다루는 법

표 4. 단어결합형식의 올림말

우의 단어결합들가운데서 길이가 9인 단어결합과 그에 따르는 ASCII 값으로 구성된 색인화일은 다음과 같다.

$\mathcal{N}_{\!\scriptscriptstyle ar{ ext{O}}}$	단어결합	ASCII 코드
1	가격제정의 통일성	23417612823417816923616015623616014923615715232
		237134181236157188236132177
2	과학의 사회적기능	23417918823714915323615715232236130172237154140
		236160129234184176235138165
3	관광객의 봉사수요	23418012823418014523417615723615715232235180137
		236130172236136152236154148
4	무용음악의 명곡화	23517218023615416923615714023614913323615715232
		235170133234179161237153148
5	문장성분의 어울림	23517218423615816523613217723518213223615715232
		236150180236154184235166188
6	붓글씨쓰는 방법	23518214723418412823614816832236147176235138148
		32235178149

표 5. 길이가 9인 단어결합형식의 올림말색인화일

대상본문에 대한 n개 글자색인화일과 단어결합형식의 올림말색인화일이 작성되면 해당한 단어결합형식의 올림말을 찾기 위한 기초자료준비가 완료되였다고 본다.

다음으로 n개 글자색인화일과 단어결합형식의 올림말색인화일의 기록들을 서로 대조하면서 해당한 단어결합을 찾는다.

일반적으로 실마리어색인화일과 단어결합형식의 올림말색인화일의 크기는 서로 다르다. 대상본문의 크기를 어떻게 정하는가에 따라 실마리어화일이 단어결합형식의 올림말색인화일보다 클수도 있고 작을수도 있다. 그러므로 두 화일중에서 화일의 크기가 큰 화일(기

록개수가 많은 화일)을 토대화일로 하고 화일의 크기가 작은 화일(기록개수가 작은 화일)을 기준화일로 정하는것이 좋다.

실례로 9개 글자로 이루어진 실마리어색인화일에서 단어결합형식의 올림말《문장성분의 어울림》을 찾아보자.

여기서는 9개 글자로 이루어진 실마리어색인화일을 토대화일로 하고 단어결합형식의 올림말색인화일을 기준화일로 정하였다.

설명의 편의를 위해 토대화일을 MS 기준화일을 BW라고 하겠다.

그러면 $MS = \{MS_i = \overline{1, 59}\}, BW = \{BW_i \mid j = \overline{1, 6}\}$

이때 $BW_i \in BW$, $MS_i \in MS$ 이다.

우의 정의에 기초하여 대조교알고리듬을 작성하면 다음과 같다.

- 1. n = Count(MS), m = Count(BW), j = 1, i = 0
- 2 $j \le m$ 인 조건에서 아래의 조작을 반복한다.
 - 1) i = i + 1
 - 2) $i \le n$ 인 조건에서 아래의 조작을 반복한다.
 - (1) $BW_j = MS_i$ 이면 MS_i 에 대한 정보를 보관하고 3)의 조작수행에로 넘어 간다.
 - (2) $BW_i \neq MS_i$ 이면 1)의 조작수행에로 넘어간다.
 - 3) j = j + 1
- 3. 작업 끝

[알고리듬 끝]

알고리듬 1의 조작수행에 의하여 MS의 기록개수는 n에 그리고 BW의 기록개수는 m에 등록하고 해당한 변수들에 초기값이 설정된다. 알고리듬 2의 조작수행에 의하여 BW의 첫번째 기록인 《가격제정의 통일성》을 MS의 기록들과 대조한다. 대조에서 성공하지 못하여 BW의 다음기록인 《과학의 사회적기능》이 선택되여 MS의 기록들과 대조한다. 여전히 대조에서 성공하지 못하고 BW의 다음기록이 선택된다. 이러한 과정이 반복되면서 BW의 다섯번째 기록인 《문장성분의 어울림》이 선택되여 MS의 기록들과 대조된다. 대조에서 성공하여 《문장성분의 어울림》에 대한 해당한 정보가 등록된다. 그리고 BW의 여섯번째 기록인 《붓글씨쓰는 방법》이 선택되여 대조를 진행하나 성공하지 못하고 알고리듬작업은 끝난다.

n개 글자색인화일과 단어결합형식의 올림말색인화일의 기록들을 대조할 때 대조항목은 실마리어 그자체가 될수도 있고 실마리어에 대응하는 ASCII 코드값이 될수도 있다.

일반적으로 대상본문의 크기가 클 때에는 대조항목을 ASCII 코드값으로 설정하는것이합리적이다. 그것은 수값대조가 글자렬대조에 비해 대조시간이 훨씬 짧기때문이다. 더우기대조시간은 글자렬의 길이에 비례하기때문에 단어결합추출에서 대조항목설정은 무시할수 없는 중요한 문제이다. 그러나 대상본문의 크기가 작을 때에는 실마리어 그자체를 대조항목으로 설정하여도 대조시간에서는 큰 차이가 없다.

우에서 서술한 수법을 리용하면 대상본문에서 단어결합형식의 올림말과 일치하는 모든 단어들은 추출할수 있지만 의미는 같고 표기가 다른 단어결합들은 추출할수 없다. 바로

이러한 문제는 사전에 동등관계를 반영해주는 방법으로 쉽게 해결할수 있다.

실례를 들면 사전에 다음과 같은 동등관계를 반영하여준다.

축적소비균형의 법칙

ㅂ 축적소비균형법칙

사회발전의 주체요인

ㅂ 사회발전에서의 주체요인

물론 의미가 일치하거나 류사한 단어결합들을 모두 언어공학적인 처리방법으로 추출 할수도 있지만 자동분류색인에서 리용되는 단어결합형식의 올림말이 많지 않은 조건에서 사 전에 동등관계를 반영하는것이 더 합리적이라고 할수 있다.

단어결합형식의 주제어추출은 어디까지나 단어결합형식의 올림말을 기준으로 하기때 문에 자동분류색인에서는 기계사전의 올림말들을 보충, 갱신하는 사업을 정상적으로 하여 분 류의 정확도에 부정적인 영향을 주지 않도록 하여야 한다.

주제어추출에서 품이 드는 공정은 대상본문을 n개의 글자로 이루어진 실마리어로 분할하는 공정이다. 그것은 단어결합형식의 올림말들의 길이가 서로 다르다는 사정과 관련된다. 그러므로 대상본문의 분할은 단어결합형식의 올림말의 최소길이가 4라는것을 고려하여 n의 최소값 4로부터 단어결합형식의 올림말의 최대길이값까지 변화시키면서 여러번 진행하여야 한다. 그래야 각이한 길이를 가진 단어결합형식의 올림말들과 대조할수 있는 토대화일들을 얻을수 있다.

물론 대상본문이 큰 경우에 수동분할은 대단히 힘든것으로 되지만 콤퓨터의 기종이 날을 따라 높아지는 오늘날 자동분할은 별로 힘든 문제도 아니며 더우기 분할시간문제도 론할 필요가 없다.

보는바와 같이 단어결합형식의 주제어추출은 언어공학적처리에 품이 많이 들지만 분류정확도제고에 큰 영향을 주기때문에 이에 대한 연구사업은 여러가지 각도에서 심화시켜 나가야 한다.

앞으로 우리는 자동분류색인에서 제기되는 세부적인 문제들에 대한 연구를 심화시켜 자동분류의 효률을 부단히 개선해나감으로써 지식경제시대의 요구에 맞게 전통도서관들을 전자도서관화하는데 적극 이바지해나가야 할것이다.

실마리어 주제어추출, 검색어사전